고객을 세그먼테이션하자 [프로젝트] - 전해진

11-2. 데이터 불러오기

데이터 살펴보기

- **테이블에 있는 10개의 행만 출력하기**

```
select *
from `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
limit 10
```

쿼리 결과 + 대화 만들기 결과 저장 다음에서 열기

작업 정보 | 결과 | 시각화 | JSON | 실행 세부정보 | 실행 그래프

행	InvoiceNo	StockCode	Description	Quantity	InvoiceDate	UnitPrice
1	536365	85123A	WHITE HANGING HEART T-LIG...	6	2010-12-01 08:26:00 UTC	
2	536365	71053	WHITE METAL LANTERN	6	2010-12-01 08:26:00 UTC	
3	536365	84406B	CREAM CUPID HEARTS COAT H...	8	2010-12-01 08:26:00 UTC	
4	536365	84029G	KNITTED UNION FLAG HOT WA...	6	2010-12-01 08:26:00 UTC	
5	536365	84029E	RED WOOLLY HOTTIE WHITE H...	6	2010-12-01 08:26:00 UTC	
6	536365	22752	SET 7 BABUSHKA NESTING BO...	2	2010-12-01 08:26:00 UTC	
7	536365	21730	GLASS STAR FROSTED T-LIGHT...	6	2010-12-01 08:26:00 UTC	
8	536366	22633	HAND WARMER UNION JACK	6	2010-12-01 08:28:00 UTC	
9	536366	22632	HAND WARMER RED POLKA DOT	6	2010-12-01 08:28:00 UTC	
10	536367	84879	ASSORTED COLOUR BIRD ORN...	32	2010-12-01 08:34:00 UTC	

- **전체 데이터는 몇 행으로 구성되어 있는지 확인하기**

```
select count(*)
from `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
```

쿼리 결과

작업 정보 | 결과 | 시각화

행	f0_
1	541909

데이터 수 세기

- **COUNT 함수를 사용해서, 각 컬럼별 데이터 포인트의 수를 세어 보기**

```
select count(InvoiceNo) as InvoiceNo_cnt,
count(StockCode) as StockCode_cnt,
count(Description) as Description_cnt,
count(Quantity) as Quantity_cnt,
count(InvoiceDate) as InvoiceDate_cnt,
count(UnitPrice) as UnitPrice_cnt,
count(CustomerID) as CustomerID_cnt,
count(Country) as Country_cnt
from `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
```

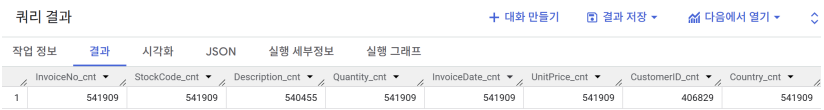

	InvoiceNo_cnt	StockCode_cnt	Description_cnt	Quantity_cnt	InvoiceDate_cnt	UnitPrice_cnt	CustomerID_cnt	Country_cnt
1	541909	541909	540455	541909	541909	541909	406829	541909

11-4. 데이터 전처리 방법(1): 결측치 제거

컬럼 별 누락된 값의 비율 계산

- **각 컬럼 별 누락된 값의 비율을 계산**
  - **각 컬럼에 대해서 누락 값을 계산한 후, 계산된 누락 값을 UNION ALL을 통해 합치기**

```
SELECT
    'InvoiceNo' AS column_name,
    ROUND(SUM(CASE WHEN InvoiceNo IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2)
    AS missing_percentage
from `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
union all
SELECT
    'StockCode' AS column_name,
    ROUND(SUM(CASE WHEN StockCode IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2)
    AS missing_percentage
from `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
union all
select
    'Description' as column_name,
    ROUND(SUM(CASE WHEN Description is null then 1 else 0 end) / count(*) * 100,2)
    as missing_percentage
from `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
union all
select
    'Quantity' as column_name,
    ROUND(SUM(CASE WHEN Quantity is null then 1 else 0 end) / count(*) * 100,2)
    as missing_percentage
from `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
union all
select
    'InvoiceDate' as column_name,
    Round(sum(case when InvoiceDate is null then 1 else 0 end) / count(*) * 100,2)
    as missing_percentage
from `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
union all
select
    'UnitPrice' as column_name,
    Round(sum(case when UnitPrice is null then 1 else 0 end) / count(*) * 100,2)
```

```
    as missing_percentage
from `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
union all
select
    'CustomerID' as column_name,
    Round(sum(case when CustomerID is null then 1 else 0 end) / count(*) * 100,2)
    as missing_percentage
from `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
union all
select
    'Country' as column_name,
    Round(sum(case when Country is null then 1 else 0 end) / count(*) * 100,2)
    as missing_percentage
from `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
```

쿼리 결과

작업 정보 | 결과 | 시각화 | JSON | 실행 세부

행	column_name	missing_percenta...
1	InvoiceNo	0.0
2	StockCode	0.0
3	Description	0.27
4	Quantity	0.0
5	InvoiceDate	0.0
6	UnitPrice	0.0
7	CustomerID	24.93
8	Country	0.0

결측치 처리 전략

- `StockCode = '85123A'` 의 `Description` 을 추출하는 쿼리문을 작성하기

```
SELECT distinct Description
from `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
where StockCode = '85123A'
```

쿼리 결과

작업 정보 | 결과 | 시각화 | JSON | 실

행	Description
1	wrongly marked carton 22804
2	WHITE HANGING HEART T-LIG...
3	CREAM HANGING HEART T-LIG...
4	?

결측치 처리

- **DELETE 구문을 사용하며, WHERE 절을 통해 데이터를 제거할 조건을 제시**

```
DELETE FROM `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
WHERE Description is null or CustomerID is null
```

쿼리 결과

작업 정보 | 결과 | 실행 세부정보 | 실행 그래프

이 문으로 user_data의 행 135,080개가 삭제되었습니다.

11-5. 데이터 전처리(2): 중복값 처리

중복값 확인

- **중복된 행의 수를 세어보기**
  - **8개의 컬럼에 그룹 함수를 적용한 후, COUNT가 1보다 큰 데이터를 세어보기**

```
select sum(cnt)
from (
          SELECT count(*) as cnt
            from `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
        group by InvoiceNo, StockCode, Description, Quantity,
                 InvoiceDate,UnitPrice, CustomerID,Country
          having count(*) > 1
      )
```

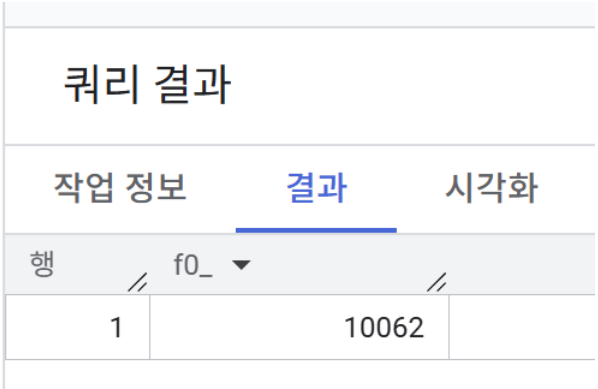

중복값 처리

- **중복값을 제거하는 쿼리문 작성하기**
  - **CREATE OR REPLACE TABLE 구문을 활용하여 모든 컬럼(*)을 DISTINCT 한 데이터로 업데이트**

```
CREATE OR REPLACE TABLE `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
  AS
      SELECT *
        from `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
    group by InvoiceNo, StockCode, Description,
             Quantity, InvoiceDate,UnitPrice, CustomerID,Country
```

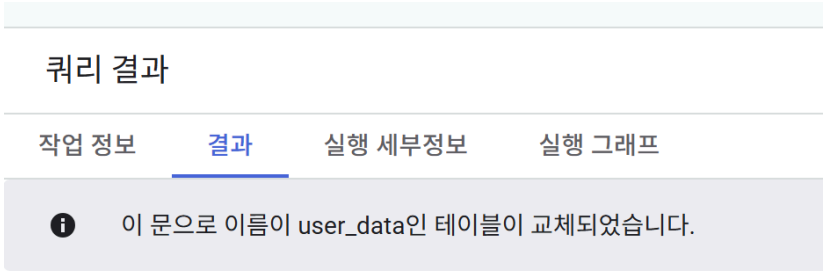

11-6. 데이터 전처리(3): 오류값 처리

`InvoiceNo` 살펴보기

- **고유(unique)한 `InvoiceNo`의 개수를 출력하기**

```
select count(distinct InvoiceNo)
from `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
```

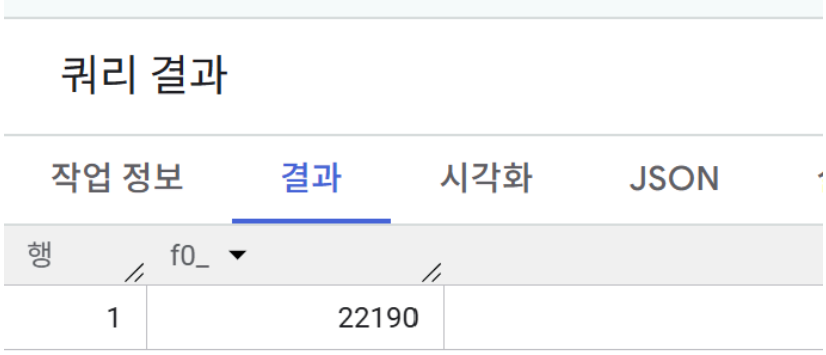

- **고유한 `InvoiceNo` 를 앞에서부터 100개를 출력하기**

```
select distinct InvoiceNo
from `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
limit 100
```

- **`InvoiceNo` 가 'C'로 시작하는 행을 필터링 할 수 있는 쿼리문을 작성하기 (100행까지만 출력)**

```
select *
from `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
where InvoiceNo like 'C%'
limit 100
```

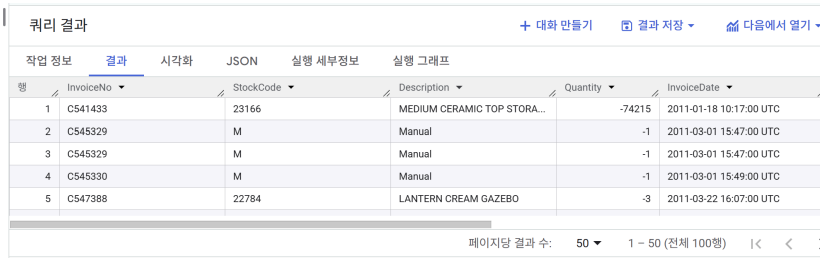

- **구매 건 상태가 `Canceled` 인 데이터의 비율(%) - 소수점 첫번째 자리까지**

```
select round(
        sum(
```

```
        case when InvoiceNo like 'C%' then 1 else 0 end ) / count(*) * 100, 1)
from `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
```

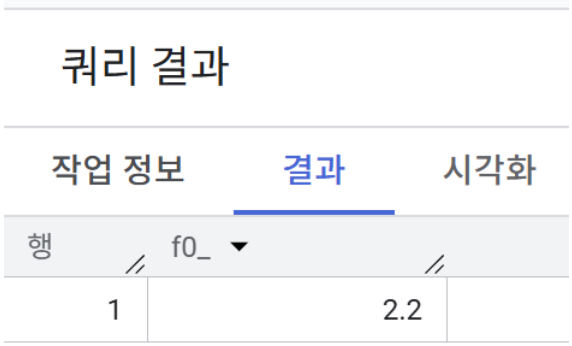

`StockCode` 살펴보기

- **고유한 `StockCode` 의 개수를 출력하기**

```
select count(distinct StockCode)
from `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
```

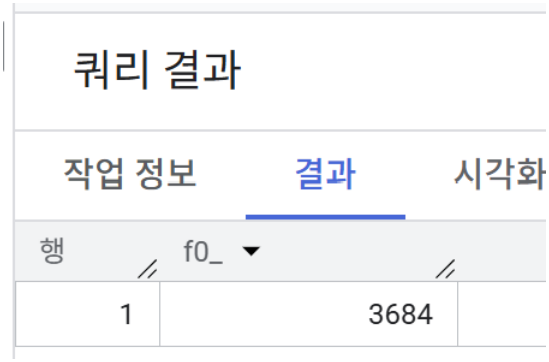

- **어떤 제품이 가장 많이 판매되었는지 보기 위하여 `StockCode` 별 등장 빈도를 출력하기**
  - 상위 10개의 제품들을 출력하기

```
select StockCode, COUNT(*) AS sell_cnt
from `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
group by StockCode
order by sell_cnt desc
limit 10
```

쿼리 결과 + 대화 만들기 결과 저장

작업 정보 | 결과 | 시각화 | JSON | 실행 세부정보 | 실행 그래프

행	StockCode	sell_cnt
1	85123A	2065
2	22423	1894
3	85099B	1659
4	47566	1409
5	84879	1405
6	20725	1346
7	22720	1224
8	POST	1196
9	22197	1110
10	23203	1108

페이지당 결과 수: 50 1 – 10 (전체 10행)

- `StockCode` **의 컬럼에 있던 값 중에서 숫자를 제외한 문자만 남기고 문자가 몇 자리 수 인지 세고**
  - **숫자가 0~1개인 값**들에는 어떤 코드들이 들어가 있는지 출력하기

```
SELECT distinct StockCode,
             LENGTH(StockCode) - number_count AS word_cnt
  FROM (
              SELECT StockCode,
                          LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', ''))
                          AS number_count
                 from `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
                )
WHERE number_count in (0,1)
```

행	StockCode	word_cnt
1	POST	4
2	M	1
3	C2	1
4	D	1
5	BANK CHARGES	12
6	PADS	4
7	DOT	3
8	CRUK	4

- `StockCode` **의 컬럼에 있던 값 중에서 숫자를 제외한 문자만 남기고 문자가 몇 자리 수 인지 세고**
  - **숫자가 0~1개인 값들을 가지고 있는 데이터 수는 전체 데이터 수 대비 몇 퍼센트**인지 구하기 (소수점 두 번째 자리까지)

```
SELECT ROUND(
                SUM(
     CASE WHEN LENGTH(StockCode)-LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', ''))
```

```
                    IN (0,1) THEN 1 ELSE 0 END) / COUNT(*) * 100,2)
from `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
```

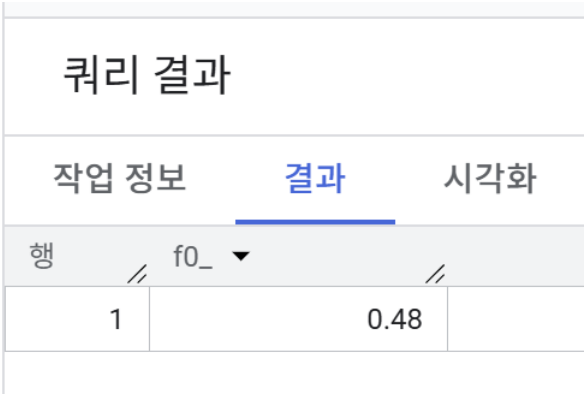

- **제품과 관련되지 않은 거래 기록을 제거하기**

```
DELETE FROM `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
WHERE StockCode IN (
                                  SELECT distinct StockCode
                                FROM (
                                          SELECT StockCode,
                                                       LENGTH(StockCode)
                                                       - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]',
''))
                                                      AS number_count
                                              from `project-ddf4c901-9232-4ab4-82b.modulabs.user_d
ata`
                                                  )
                                    WHERE number_count in (0,1)
                                       )
```

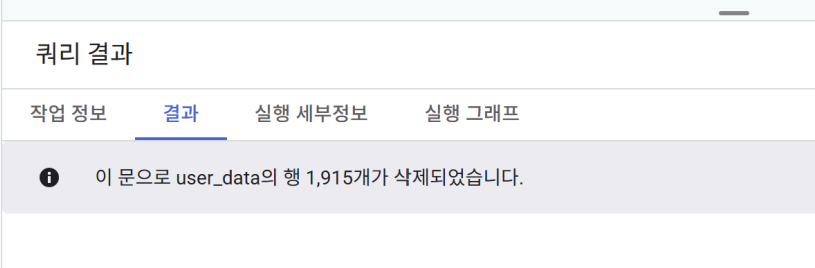

`Description` 살펴보기

- **고유한 Description 별 출현 빈도를 계산하고 상위 30개를 출력하기**

```
SELECT Description, COUNT(*) AS description_cnt
FROM `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
group by Description
```

```
order by description_cnt desc
limit 30;
```

쿼리 결과

+ 대화 만들기 결과 저장

작업 정보 결과 시각화 JSON 실행 세부정보 실행 그래프

행	Description	description_cnt
1	WHITE HANGING HEART T-LIG...	2058
2	REGENCY CAKESTAND 3 TIER	1894
3	JUMBO BAG RED RETROSPOT	1659
4	PARTY BUNTING	1409
5	ASSORTED COLOUR BIRD ORN...	1405

페이지당 결과 수: 50 1 – 30 (전체 30행)

- **서비스 관련 정보를 포함하는 행들을 제거하기**

```
DELETE
FROM project_name.modulabs_project.data
WHERE Description in ('Next Day Carriage','High Resolution Image')
```

쿼리 결과

작업 정보 결과 실행 세부정보 실행 그래프

이 문으로 user_data의 행 83개가 삭제되었습니다.

- **대소문자를 혼합하고 있는 데이터를 대문자로 표준화 하기**

```
CREATE OR REPLACE TABLE `project-ddf4c901-9232-4ab4-82b.modulabs.user_data` AS
SELECT
  * EXCEPT (Description),
  UPPER(Description) AS Description
FROM `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
```

쿼리 결과

작업 정보 결과 실행 세부정보 실행 그래프

이 문으로 이름이 user_data인 테이블이 교체되었습니다.

`UnitPrice` 살펴보기

- `UnitPrice` 의 최솟값, 최댓값, 평균을 구하기

```
SELECT MIN(UnitPrice) AS min_price,
             MAX(UnitPrice) AS max_price,
             AVG(UnitPrice) AS avg_price
  FROM project_name.modulabs_project.data;
```

쿼리 결과

작업 정보 | 결과 | 시각화 | JSON | 실행 세부정보

행	min_price	max_price	avg_price
1	0.0	649.5	2.904956757406...

- 단가가 0원인 거래의 개수, 구매 수량(`Quantity`)의 최솟값, 최댓값, 평균 구하기

```
SELECT count(quantity) as cnt_quantity,
             min(Quantity) as min_quantity,
             max(Quantity) as max_quantity,
             avg(Quantity) as avg_quantity
    FROM `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
 WHERE UnitPrice = 0
```

쿼리 결과

작업 정보 | 결과 | 시각화 | JSON | 실행 세부정보 | 실행 그래프

행	cnt_quantity	min_quantity	max_quantity	avg_quantity
1	33	1	12540	420.5151515151...

- `UnitPrice = 0` 를 제거하고 일관된 데이터셋을 유지하기

```
CREATE OR REPLACE TABLE project_name.modulabs_project.data AS
SELECT *
FROM project_name.modulabs_project.data
WHERE UnitPrice != 0
```

[결과 이미지를 넣어주세요]

쿼리 결과

작업 정보 | 결과 | 실행 세부정보 | 실행 그래프

이 문으로 이름이 user_data인 테이블이 교체되었습니다.

11-7. RFM 스코어

Recency

- `InvoiceDate` **컬럼을 연월일 자료형으로 변경하기**

```
SELECT DATE(InvoiceDate) InvoiceDay, *
FROM project_name.modulabs_project.data;
```

쿼리 결과 + 대화 만들기 결과 저장 다음에서 열기

작업 정보 | 결과 | 시각화 | JSON | 실행 세부정보 | 실행 그래프

행	InvoiceDay	InvoiceNo	StockCode	Quantity	InvoiceDate	UnitPrice	CustomerID	Country	Description
1	2011-01-18	541431	23166	74215	2011-01-18 10:01:00 UTC	1.04	12346	United Kingdom	MEDIUM CERAMIC TOP S
2	2011-01-18	C541433	23166	-74215	2011-01-18 10:17:00 UTC	1.04	12346	United Kingdom	MEDIUM CERAMIC TOP S
3	2010-12-07	537626	84969	6	2010-12-07 14:57:00 UTC	4.25	12347	Iceland	BOX OF 6 ASSORTED COL
4	2010-12-07	537626	84997B	6	2010-12-07 14:57:00 UTC	3.75	12347	Iceland	RED 3 PIECE RETROSPOT
5	2010-12-07	537626	22497	4	2010-12-07 14:57:00 UTC	4.25	12347	Iceland	SET OF 2 TINS VINTAGE E
6	2010-12-07	537626	22195	12	2010-12-07 14:57:00 UTC	1.65	12347	Iceland	LARGE HEART MEASURIN

페이지당 결과 수: 50 1 – 50 (전체 399573행)

- **가장 최근 구매 일자를 MAX() 함수로 찾아보기**

```
SELECT DATE(InvoiceDate) InvoiceDay,
            DATE(MAX(InvoiceDate) OVER ()) most_recent_date,
            *
  FROM `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
```

쿼리 결과

+ 대화 만들기 결과 저장 다음에서 열기

작업 정보 결과 시각화 JSON 실행 세부정보 실행 그래프

행	InvoiceDay	most_recent_date	InvoiceNo	StockCode	Quantity	InvoiceDate
1	2011-01-18	2011-12-09	541431	23166	74215	2011-01-18 10:01:00 UTC
2	2011-01-18	2011-12-09	C541433	23166	-74215	2011-01-18 10:17:00 UTC
3	2010-12-07	2011-12-09	537626	84969	6	2010-12-07 14:57:00 UTC
4	2010-12-07	2011-12-09	537626	84997B	6	2010-12-07 14:57:00 UTC
5	2010-12-07	2011-12-09	537626	22497	4	2010-12-07 14:57:00 UTC
6	2010-12-07	2011-12-09	537626	22195	12	2010-12-07 14:57:00 UTC
7	2010-12-07	2011-12-09	537626	22771	12	2010-12-07 14:57:00 UTC
8	2010-12-07	2011-12-09	537626	22775	12	2010-12-07 14:57:00 UTC
9	2010-12-07	2011-12-09	537626	22212	6	2010-12-07 14:57:00 UTC
10	2010-12-07	2011-12-09	537626	22774	12	2010-12-07 14:57:00 UTC

페이지당 결과 수: 50 1 – 50 (전체 399573행)

- **유저 별로 가장 큰 InvoiceDay를 찾아서 가장 최근 구매일로 저장하기**

```
SELECT CustomerID, MAX(DATE(InvoiceDate)) as InvoiceDay
FROM `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
GROUP BY CustomerID
```

쿼리 결과

+ 대화 만들기 결과 저장

작업 정보 결과 시각화 JSON 실행 세부정보 실행 그래프

행	CustomerID	InvoiceDay
1	12346	2011-01-18
2	12347	2011-12-07
3	12348	2011-09-25
4	12349	2011-11-21
5	12350	2011-02-02

페이지당 결과 수: 50 1 – 50 (전체 4362행)

- **가장 최근 일자(`most_recent_date`)와 유저별 마지막 구매일(`InvoiceDay`)간의 차이를 계산하기**

```
SELECT
  CustomerID,
  EXTRACT(DAY FROM MAX(InvoiceDay) OVER () - InvoiceDay) AS recency
FROM (
  SELECT
    CustomerID,
    MAX(DATE(InvoiceDate)) AS InvoiceDay
  FROM project_name.modulabs_project.data
  GROUP BY CustomerID
);
```

쿼리 결과

+ 대화 만들기 결과 저장 다

작업 정보 결과 시각화 JSON 실행 세부정보 실행 그래프

행	CustomerID	recency
1	12350	310
2	12361	287
3	12725	371
4	12809	168
5	13040	8
6	13068	10
7	13098	1
8	13170	26

페이지당 결과 수: 50 1 – 50 (전체 4362행)

- **최종 데이터 셋에 필요한 데이터들을 각각 정제해서 이어붙이고 지금까지의 결과를 `user_r` 이라는 이름의 테이블로 저장하기**

```
CREATE OR REPLACE TABLE `project-ddf4c901-9232-4ab4-82b.modulabs.user_r`
AS
        SELECT
            CustomerID,
            EXTRACT(DAY FROM MAX(InvoiceDay) OVER () - InvoiceDay) AS recency
            FROM (
                        SELECT
                                CustomerID,
                                MAX(DATE(InvoiceDate)) AS InvoiceDay
                            FROM `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
                            GROUP BY CustomerID
                    )
```

작업 정보 결과 실행 세부정보 실행 그래프

이 문으로 이름이 user_r인 새 테이블이 생성되었습니다.

Frequency

- **고객마다 고유한 InvoiceNo의 수를 세어보기**

```
SELECT CustomerID, count(distinct InvoiceNo)
FROM `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
GROUP BY CustomerID
```

행	CustomerID	f0_
1	12346	2
2	12347	7
3	12348	4
4	12349	1
5	12350	1
6	12352	8
7	12353	1
8	12354	1

- **각 고객 별로 구매한 아이템의 총 수량 더하기**

```
SELECT CustomerID, SUM(Quantity)
FROM `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
GROUP BY CustomerID
```

행	CustomerID	f0_
1	12346	0
2	12347	2458
3	12348	2332
4	12349	630

- **전체 거래 건수 계산와 구매한 아이템의 총 수량 계산의 결과를 합쳐서 `user_rf` 라는 이름의 테이블에 저장하기**

```
CREATE OR REPLACE TABLE `project-ddf4c901-9232-4ab4-82b.modulabs.user_rf` AS
WITH purchase_cnt AS (
                SELECT CustomerID, count(distinct InvoiceNo) AS purchase_cnt
                    FROM `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
            GROUP BY CustomerID
),

item_cnt AS (
            SELECT CustomerID, SUM(Quantity) item_cnt
                  FROM `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
            GROUP BY CustomerID
)

SELECT
  pc.CustomerID,
  pc.purchase_cnt,
  ic.item_cnt,
  ur.recency
FROM purchase_cnt AS pc
JOIN item_cnt AS ic
  ON pc.CustomerID = ic.CustomerID
```

```
JOIN `project-ddf4c901-9232-4ab4-82b.modulabs.user_r` AS ur
  ON pc.CustomerID = ur.CustomerID
```

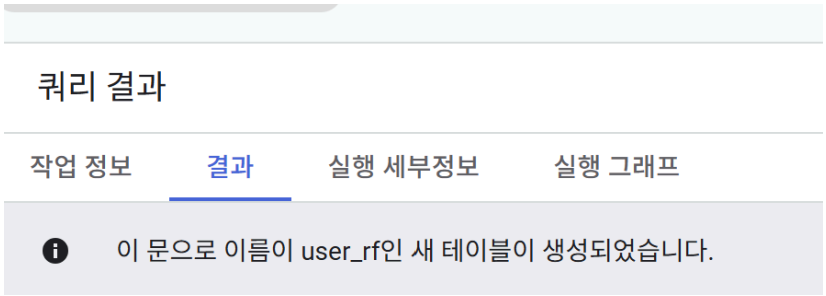

Monetary

- **고객별 총 지출액 계산 (소수점 첫째 자리에서 반올림)**

```
        SELECT CustomerID, ROUND(SUM(UnitPrice*Quantity),1) AS user_total
                  FROM `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
            GROUP BY CustomerID
```

- **고객별 평균 거래 금액 계산**
  - **고객별 평균 거래 금액을 구하기 위해 1) `data` 테이블을 `user_rf` 테이블과 조인(LEFT JOIN) 한 후, 2) `purchase_cnt`로 나누어서 3) `user_rfm` 테이블로 저장하기**

```
CREATE OR REPLACE TABLE `project-ddf4c901-9232-4ab4-82b.modulabs.user_rfm` AS
SELECT
  rf.CustomerID AS CustomerID,
  rf.purchase_cnt,
  rf.item_cnt,
  rf.recency,
  ut.user_total,
  ut.user_total / rf.purchase_cnt as user_average
FROM `project-ddf4c901-9232-4ab4-82b.modulabs.user_rf` rf
LEFT JOIN (
  -- 고객 별 총 지출액
```

```
  SELECT CustomerID, ROUND(SUM(UnitPrice*Quantity),1) AS user_total
                 FROM `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
            GROUP BY CustomerID
) ut
ON rf.CustomerID = ut.CustomerID
```

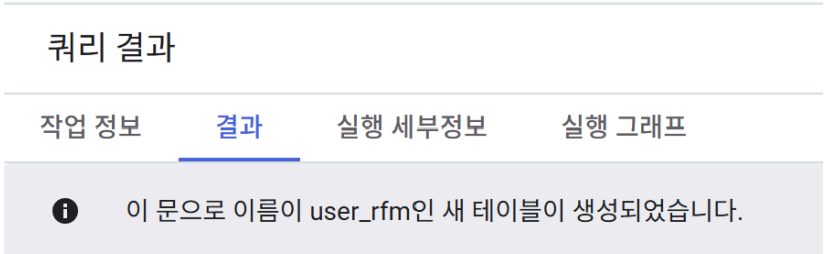

RFM 통합 테이블 출력하기

- **최종 user_rfm 테이블을 출력하기**

```
select *
from `project-ddf4c901-9232-4ab4-82b.modulabs.user_rfm`
```

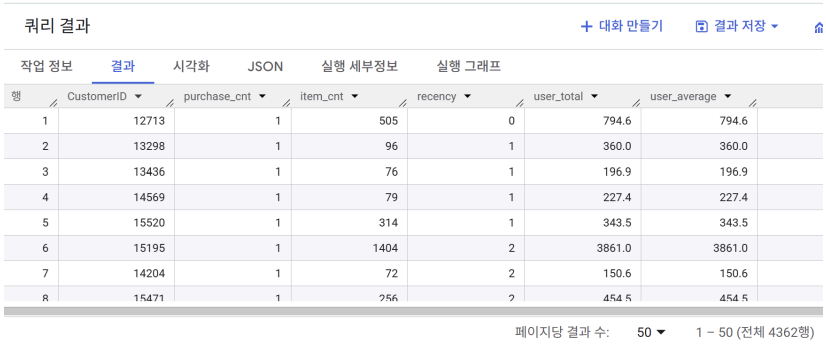

행	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average
1	12713	1	505	0	794.6	794.6
2	13298	1	96	1	360.0	360.0
3	13436	1	76	1	196.9	196.9
4	14569	1	79	1	227.4	227.4
5	15520	1	314	1	343.5	343.5
6	15195	1	1404	2	3861.0	3861.0
7	14204	1	72	2	150.6	150.6
8	15471	1	256	2	454.5	454.5

11-8. 추가 Feature 추출

1. 구매하는 제품의 다양성

- **1) 고객 별로 구매한 상품들의 고유한 수를 계산하기**
  2) `user_rfm` 테이블과 결과를 합치기
  3) `user_data` 라는 이름의 테이블에 저장하기

```
CREATE OR REPLACE TABLE `project-ddf4c901-9232-4ab4-82b.modulabs.user_data1` AS
WITH unique_products AS (
  SELECT
    CustomerID,
    COUNT(DISTINCT StockCode) AS unique_products
```

```
  FROM `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
  GROUP BY CustomerID
)
SELECT ur.*, up.* EXCEPT (CustomerID)
FROM `project-ddf4c901-9232-4ab4-82b.modulabs.user_rfm` AS ur
JOIN unique_products AS up
ON ur.CustomerID = up.CustomerID
```

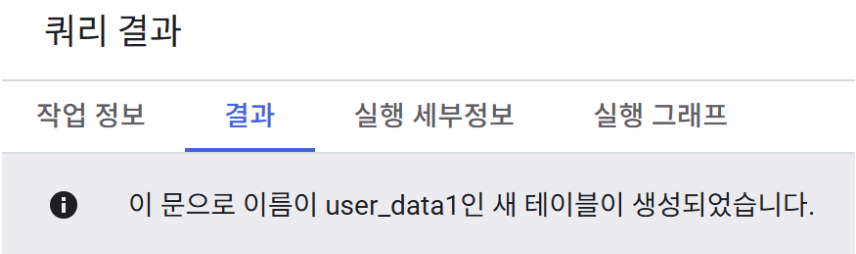

2. 평균 구매 주기

- **고객들의 쇼핑 패턴을 이해하는 것을 목표 (고객 별 재방문 주기 살펴보기)**
  - **균 구매 소요 일수를 계산하고, 그 결과를 `user_data` 에 통합**

```
CREATE OR REPLACE TABLE `project-ddf4c901-9232-4ab4-82b.modulabs.user_data1` AS
WITH purchase_intervals AS (
  -- (2) 고객 별 구매와 구매 사이의 평균 소요 일수
  SELECT
    CustomerID,
    CASE WHEN ROUND(
                            AVG(interval_), 2) IS NULL
                  THEN 0 ELSE ROUND(AVG(interval_), 2) END AS average_interval
  FROM (
    -- (1) 구매와 구매 사이에 소요된 일수
    SELECT
      CustomerID,
      DATE_DIFF(InvoiceDate, LAG(InvoiceDate)
      OVER (PARTITION BY CustomerID ORDER BY InvoiceDate), DAY) AS interval_
    FROM
      `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
    WHERE CustomerID IS NOT NULL
  )
  GROUP BY CustomerID
)

SELECT u.*, pi.* EXCEPT (CustomerID)
FROM `project-ddf4c901-9232-4ab4-82b.modulabs.user_data1` AS u
LEFT JOIN purchase_intervals AS pi
ON u.CustomerID = pi.CustomerID;
```

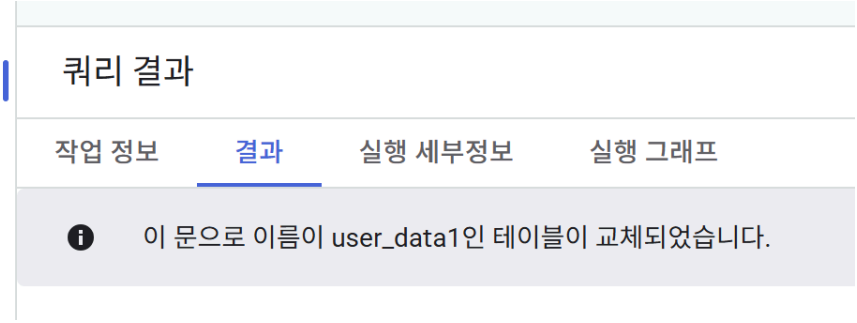

3. 구매 취소 경향성

- **고객의 취소 패턴 파악하기**
  1) 취소 빈도(cancel_frequency) : 고객 별로 취소한 거래의 총 횟수
  2) 취소 비율(cancel_rate) : 각 고객이 한 모든 거래 중에서 취소를 한 거래의 비율
  - **취소 빈도와 취소 비율을 계산하고 그 결과를 `user_data` 에 통합하기**
    (취소 비율은 소수점 두번째 자리)

```
CREATE OR REPLACE TABLE `project-ddf4c901-9232-4ab4-82b.modulabs.user_data1` AS
WITH TransactionInfo AS (
      SELECT
            CustomerID,
            count(*) AS total_transactions,
            SUM(CASE WHEN InvoiceNo LIKE 'C%' THEN 1 ELSE 0 END) AS cancel_frequency
          FROM `project-ddf4c901-9232-4ab4-82b.modulabs.user_data`
    group by CustomerID
)

SELECT u.*, t.* EXCEPT(CustomerID), cancel_frequency/total_transactions AS cancel_rate
  FROM `project-ddf4c901-9232-4ab4-82b.modulabs.user_data1` AS u
  LEFT JOIN TransactionInfo AS t
    ON u.CustomerID = t.CustomerID
```

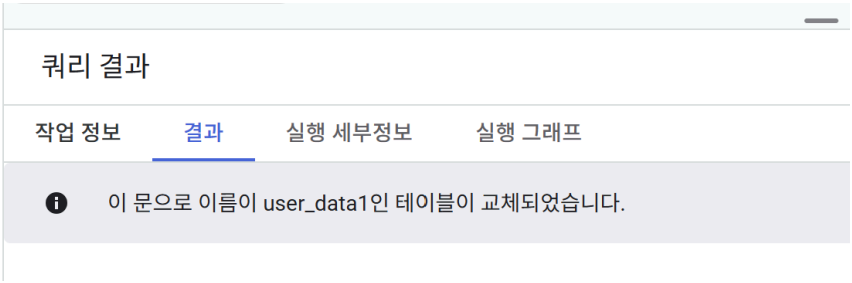

- **다양한 컬럼들을 활용하여 고객의 구매 패턴과 선호도를 보다 심층적으로 이해할 수 있도록 최종적으로 `user_data` 를 출력하기**

```
select *
  from `project-ddf4c901-9232-4ab4-82b.modulabs.user_data1`
```

쿼리 결과

+ 대화 만들기 결과 저장 다음에서 열기

작업 정보 결과 시각화 JSON 실행 세부정보 실행 그래프

행	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average	unique_products	average_interval	total_transactions	c
1	17936	1	257	5	380.1	380.1	68	0.0	72	
2	15006	1	285	51	475.4	475.4	120	0.0	131	
3	14382	1	1231	26	615.5	615.5	121	0.0	126	
4	13259	1	126	61	283.2	283.2	77	0.0	81	
5	17614	1	235	57	386.3	386.3	97	0.0	98	

페이지당 결과 수: 50 1 – 50 (전체 4362행)

회고

[회고 내용을 작성해주세요]

Keep : 효율적인 쿼리 작성을 위해 고민하고 있습니다. 일할땐 실행 계획도 보곤했는데 그건 기억이 전혀 안나네요..ㅎ..

Problem :

초기 테이블을 user_data로 저장해서 뒤쪽에 헷갈린 점과

create as select 할때 제외해야할 걸로 생성한 점

롤백 비슷한걸 찾아서 되돌리긴했는데 제대로 된건지 모르겠습니다.. 일단 다시 한번 제가 작성한 코드 보고 다시 돌려봐야할 같습니다.

Try : with 절을 많이 썼는데, with절 대신 서브쿼리를 쓸 수 있는 건 없는지 등 다른 방식으로도 코드 작성을

해보려고 합니다. 일할 땐 case when도 쓰고 decode도 많이 썼던 거 같은데 빅쿼리나 mysql에선 다른 코드인거 같아서 더 찾아보려고 합니다.